

カルマンフィルタの基礎

京都大学 防災研究所

榎本 剛

eno@dpac.dpri.kyoto-u.ac.jp

2013年8月21日



第17回データ同化夏の学校

講義内容

本講義では，簡単な例を用いてカルマンフィルタの基礎について学ぶ。

- 線型フィルタ
- カルマン smoother
- 拡張カルマンフィルタ
- アンサンブル・カルマンフィルタ



副読本

- Rodgers, Clive, D, 2000: Inverse methods for atmospheric sounding: theory and practice. World Scientific, Singapore, 240pp.
- Kalnay, Eugenia, 2003: Atmospheric modeling, data assimilation and predictability. Cambridge, UK, 341pp.
- 露木義・川畑拓矢（編）, 2008: 気象学におけるデータ同化. 気象研究ノート 217, 日本気象学会, 東京, 277.

データ同化の原理

- 精度の良いデータに重く , 悪いデータに軽く重みをつけて平均する。

$$x^a = \frac{1/\sigma_1^2}{1/\sigma_1^2 + 1/\sigma_2^2} x_1 + \frac{1/\sigma_2^2}{1/\sigma_1^2 + 1/\sigma_2^2} x_2 \quad (1)$$

$$\frac{1}{\sigma^2} = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} \quad (2)$$

- 予報を観測で修正する。(1: 予測 x^f , 誤差 η , 2: 観測 y , 誤差 ε)

$$x^a = x^f + \frac{1/\sigma_\varepsilon^2}{1/\sigma_\eta^2 + 1/\sigma_\varepsilon^2} (y - x^f) \quad (3)$$

カルマンフィルタ適用の前提

カルマンフィルタは、以下のような条件の下で有効である。

- 場の時間発展を記述するモデルがある。

$$\boldsymbol{x}_t = M_t(\boldsymbol{x}_{t-1}) + \boldsymbol{\eta}_t \quad (4)$$

- 連続的に観測データが得られている。

$$\boldsymbol{y}_t = H_t(\boldsymbol{x}_t) + \boldsymbol{\varepsilon}_t \quad (5)$$

線型フィルタ

基本的なカルマンフィルタは，線型問題に適用される。

$$\boldsymbol{x}_t = \mathbf{M}_t \boldsymbol{x}_{t-1} + \boldsymbol{\eta}_t \quad (6)$$

$$\boldsymbol{y}_t = \mathbf{H}_t \boldsymbol{x}_{t-1} + \boldsymbol{\varepsilon}_t \quad (7)$$

予報

$$\boldsymbol{x}_t^f = \mathbf{M}_t \boldsymbol{x}_{t-1}^a \quad (8)$$

$$\mathbf{P}_t^f = \mathbf{M}_t \mathbf{P}_{t-1}^a \mathbf{M}_t^T + \mathbf{Q}_t \quad (9)$$

解析

$$\mathbf{K}_t = \mathbf{P}_t^f \mathbf{H}_t^T (\mathbf{H}_t \mathbf{P}_t^f \mathbf{H}_t^T + \mathbf{R})^{-1} \quad (10)$$

$$\mathbf{x}_t^a = \mathbf{x}_t^f + \mathbf{K}_t (\mathbf{y}_t - \mathbf{H}_t \mathbf{x}_t^f) \quad (11)$$

$$\mathbf{P}_t^a = (\mathbf{I} - \mathbf{K}_t \mathbf{H}_t) \mathbf{P}_t^f \quad (12)$$

\mathbf{K}_t は時刻 t におけるカルマンゲインである。

この定式化では、時刻 t までの観測を連続的に同化し、時刻 t における最適な推定値を与える。

カルマンゲインは最適内挿法の重みと同形であるが、予報誤差共分散が時間発展するとともに変化していく。

例：酔歩

時間発展は次の式で与えられる。

$$x_t = x_{t-1} + \eta_t \quad (13)$$

η_t の分散は, σ_η^2 で与えられる。位置は, 時刻 $t = 0, 1, \dots$ において直接観測され, 欠測や不良データはないとする。

$$y_t = x_t + \varepsilon_t \quad (14)$$

ε_t の分散は, σ_ε^2 とする。



予報

$$x_t^f = x_{t-1}^a \quad (15)$$

$$\sigma_t^{f2} = \sigma_{t-1}^{a2} + \sigma_\eta^2 \quad (16)$$

カルマンゲイン

$$K_t = \frac{\sigma_{t-1}^{a2} + \sigma_\eta^2}{\sigma_{t-1}^{a2} + \sigma_\eta^2 + \sigma_\varepsilon^2} \quad (17)$$

解析

$$x_t^a = x_{t-1}^f + K_t(y_t - x_t^f) \quad (18)$$

$$\sigma_t^{a2} = (1 - K_t)\sigma_t^{f2} \quad (19)$$

Octave

- MATLAB[®] ほぼ互換。
- 配列の添字はFortranと同じ1から。でもCと同じcolumn major。
- start:interval:stopでstartからstopまで刻み幅intervalのベクトルを生成。
forループにも用いる。
- .* は要素毎の積, * は行列やベクトルの積。累乗や商も同様。
- 行末の;は出力抑制。



酔歩: 数値実験

- η の確率密度分布は , 平均 0 , 分散 $\sigma_\eta^2 = 1$ の正規分布 $N(0, 1)$ に従う。
- σ_ε^2 の振幅は平均 0 , 標準偏差 2 の正規分布に従い , 観測毎に異なる。


$$N(0, \sigma_\varepsilon^2) = \sigma_\varepsilon N(0, 1) = \sqrt{2} N(0, 1) N(0, 1)$$

酔歩: 真値

```
nstep = 20;  
xt = zeros(nstep+1, 1);    % truth  
vq = 1;                   % model error variance  
q = randn(nstep+1, 1);    % model error  
for n=2:nstep+1  
    xt(n) = xt(n-1) + q(n); % truth  
endfor
```


酔歩: 観測

```
vr = 2*randn(nstep+1,1).^2;           % obs error variance  
r = sqrt(vr) .* randn(nstep+1, 1);    % obs error  
y = xt + r;                           % observation
```



酔歩: カルマンフィルタ

```
xf(1) = xt(1);  
vf(1) = vq;  
for n=2:nstep+1  
    xf(n) = xa(n-1); % forecast NB. M=1  
    vf(n) = va(n-1) + vq;  
    kg(n) = vf(n) / (vf(n) + vr(n)); % Kalman gain  
    xa(n) = xf(n) + kg(n)*(y(n) - xf(n)); % analysis  
    va(n) = (1 - kg(n)) * vf(n);  
endfor
```



課題1

モデル誤差分散 σ_η^2 だけでなく、観測誤差分散 σ_ε^2 も一定であるとき、解析誤差分散 σ_t^{a2} は時刻 $t \rightarrow \infty$ でどのようなになるか述べよ。また、数値実験でも確認せよ。


課題1 解答

σ^{a2} は一定になると考えられる。このとき ,

$$\sigma^{a2} = (1 - K_t) \left(\sigma^{a2} + \sigma_{\eta}^2 \right) = \frac{\sigma_{\varepsilon}^2 \left(\sigma^{a2} + \sigma_{\eta}^2 \right)}{\sigma^{a2} + \sigma_{\eta}^2 + \sigma_{\varepsilon}^2} \quad (20)$$

$\sigma^{a2} > 0$ となる解より次を得る。

$$\sigma^{a2} = \frac{-\sigma_{\eta}^2 + \sqrt{\sigma_{\eta}^4 + 4\sigma_{\varepsilon}^2\sigma_{\eta}^2}}{2} \quad (21)$$



カルマンスムーザ

既已取得されている観測すべてを使ってデータ同化を行う場合は、解析時刻の前だけでなく後の観測も利用することができる。これをカルマンスムーザという。

- 前方にカルマンフィルタを適用し、予報値（アプリアリ）と解析値（推定値）を得る。
- 後方にカルマンフィルタを適用し、アプリアリと推定値を得る。
- 観測は一度だけ用いるという条件があるので、前方のアプリアリと後方の推定値、または前方の推定値と後方のアプリアリとの重み付き平均をとる。



後方推定を下線で表すと以下のようなになる。

$$\underline{x}_t^f = \underline{M}_t \underline{x}_{t+1}^a \quad (22)$$

$$\underline{P}_t^f = \underline{M}_t \underline{P}_{t+1}^a \underline{M}_t^T + \underline{Q}_t \quad (23)$$

$$\underline{K}_t = \underline{P}_t^f \underline{H}_t^T (\underline{H}_t \underline{P}_t^f \underline{H}_t^T + \underline{R})^{-1} \quad (24)$$

$$\underline{x}_t^a = \underline{x}_t^f + \underline{K}_t (\underline{y}_t - \underline{H}_t \underline{x}_t^f) \quad (25)$$

$$\underline{P}_t^a = (\underline{I} - \underline{K}_t \underline{H}_t) \underline{P}_t^f \quad (26)$$

前方のアプリオリ x_t^f と後方の推定値 x_t^a を以下のように組み合わせる。


$$\tilde{P}_t^{-1} = \left(P_t^{f-1} + P_t^{a-1} \right) \quad (27)$$


$$\tilde{x}_t = \tilde{P}_t (P_t^{f-1} x_t^f + P_t^{a-1} x_t^a) \quad (28)$$

酔歩: カルマンスムーザ

```
vqb = 1;                                % model error variance
xab(nstep+1) = xa(nstep+1);             % start from forward analysis
vab(nstep+1) = va(nstep+1);
xac(nstep+1) = xa(nstep+1);
vac(nstep+1) = va(nstep+1);
for n=nstep:-1:1
    xfb(n) = xab(n+1);                   % backward forecast NB.  $M' = 1$ 
    vfb(n) = vab(n+1) + vqb;
    kgb(n) = vfb(n) / (vfb(n) + vr(n));
    xab(n) = xfb(n) + kgb(n) * (y(n) - xfb(n));
    vab(n) = (1 - kgb(n)) * vfb(n);
    vac(n) = vf(n)*vab(n) / (vf(n) + vab(n));
    xac(n) = vac(n)*(xf(n)/vf(n) + xab(n)/vab(n));
endfor
```







課題2

モデルMが時刻 t に依存しないとき，前方及び後方過程は次のように書ける。

$$x_t = Mx_{t-1} + \eta_t \quad (29)$$

$$x_{t-1} = \underline{M}x_t + \underline{\eta}_{t-1} \quad (30)$$

η_t と x_{t-1} , $\underline{\eta}_{t-1}$ と x_t はそれぞれ無相関であるとき , x_t と x_{t-1} とのラグ共分散を二つの方法で表記し , 後方モデル \underline{M} を前方モデルMで表せ。

課題2 解答

$$\mathbf{L} \equiv E(\mathbf{x}_t \mathbf{x}_{t-1}^T) = E(\mathbf{M} \mathbf{x}_{t-1} \mathbf{x}_{t-1}^T + \boldsymbol{\eta}_t \mathbf{x}_{t-1}^T) = \mathbf{M} \mathbf{P}^f \quad (31)$$

$$\mathbf{L}^T \equiv E(\mathbf{x}_{t-1} \mathbf{x}_t^T) = E(\underline{\mathbf{M}} \mathbf{x}_t \mathbf{x}_t^T + \underline{\boldsymbol{\eta}}_{t-1} \mathbf{x}_t^T) = \underline{\mathbf{M}} \mathbf{P}^f \quad (32)$$

従って

$$\underline{\mathbf{M}} = \mathbf{P}^f \mathbf{M}^T \mathbf{P}^{f-1} \quad (33)$$

接線型モデル

基本解 x に対する擾乱 δx について, 時刻 $t-1$ から t までの非線型モデルによる時間発展を考える。

$$x_t = M_t(x_{t-1}) \quad (34)$$

x_{t-1} の周りで Taylor 展開を施すと

$$\begin{aligned} x_t + \delta x_t &= M_t(x_{t-1} + \delta x_{t-1}) \\ &= M_t(x_{t-1}) + \mathbf{M}_t \delta x_{t-1} + O(|\delta x|^2) \end{aligned} \quad (35)$$

ここで

$$\mathbf{M}_t \equiv \frac{\partial M(\mathbf{x}_t)}{\partial \mathbf{x}} \quad (36)$$

である。

従って，線型性が成り立つ場合，擾乱 $\delta \mathbf{x}$ の時間発展は

$$\delta \mathbf{x}_t = \mathbf{M}_t \delta \mathbf{x}_{t-1} \quad (37)$$

で記述される。

接線型モデルの随伴 (adjoint) \mathbf{M}^T を随伴モデルという。

拡張カルマンフィルタ

モデルまたは観測演算子が非線型の場合は，拡張カルマンフィルタが用いられる。予報値は，非線型モデルを用いて計算する。

$$\boldsymbol{x}_t^f = M_t(\boldsymbol{x}_{t-1}^a) \quad (38)$$

予報誤差共分散は， \boldsymbol{x}_{t-1}^a のまわりに線型化したモデルを用いて計算する。

$$\mathbf{M}_t = \frac{\partial M(\boldsymbol{x}_{t-1}^a)}{\partial \boldsymbol{x}} \quad (39)$$

$$\mathbf{P}_t^f = \mathbf{M}_t \mathbf{P}_{t-1}^a \mathbf{M}_t^T + \mathbf{Q}_t \quad (40)$$

カルマンゲインは、線型化された観測演算子を用いて計算する。

$$\mathbf{H}_t = \frac{\partial H(\mathbf{x}_t^f)}{\partial \mathbf{x}} \quad (41)$$

$$\mathbf{K}_t = \mathbf{P}_t^f \mathbf{H}_t^T (\mathbf{H}_t \mathbf{P}_t^f \mathbf{H}_t^T + \mathbf{R})^{-1} \quad (42)$$

解析値の計算には、非線型の観測演算子を用いる。

$$\mathbf{x}_t^a = \mathbf{x}_t^f + \mathbf{K}_t [\mathbf{y}_t - H(\mathbf{x}_t^f)] \quad (43)$$

$$\mathbf{P}_t^a = (\mathbf{I} - \mathbf{K}_t \mathbf{H}_t) \mathbf{P}_t^f \quad (44)$$

アンサンブル・カルマンフィルタ

- アンサンブル平均からのずれ $\delta x = x_k^f - \bar{x}^f$ を誤差の標本とみなして，予報誤差共分散を推定。

$$\mathbf{P}^f \approx \frac{1}{K-1} \sum_{k=1}^K K \delta x_k^f \delta x_k^{fT} \quad (45)$$

- 摂動観測法では，観測に摂動を与えて各メンバー独立に観測を同化。
- 平方根フィルタは，観測をアンサンブル平均に同化する。解析の摂動は予報の摂動の線型結合で表す。

$$\delta x_t^a = \delta x_t^f T \quad (46)$$

アンサンブル・カルマンフィルタの利点

- 拡張カルマンフィルタよりも計算コストが低い。
- 接線型モデル，随伴モデルが不要。
- 時間発展する予報誤差共分散が陽に得られる。
- データ同化と同時にアンサンブル予報の初期擾乱を作成できる。

アンサンブル・カルマンフィルタの欠点

- モデルの自由度に比べてアンサンブル数が少ないため，サンプリング誤差が生じる。
- 偽りの相関による影響を取り除くため，局所化が必要。
- アンサンブル・スプレッドの過小評価を補うため，人工的なインフレーションが必要。
- 観測演算子やシステムには線型性，解析変数にはガウス分布を仮定している。

局所アンサンブル変換カルマンフィルタ

local ensemble transform Kalman filter (Hunt et al. 2007)

- 平方根フィルタの一つ。
- モデルの一部の領域で解析を行う。
- 領域毎に異なる線型結合をとることができるので、サンプリング誤差が軽減される。
- 並列計算機に適している。

LETKF: 解析

$$\overline{x^a} = \overline{x^f} + \mathbf{X}^f \overline{w^a} \quad (47)$$

\mathbf{X}^f の第 k 列は予報の摂動 δx^f 重みは次のように求める。

$$\overline{w^a} = \mathbf{P}^a \mathbf{Y}^{fT} \mathbf{R}^{-1} (\mathbf{y} - \overline{\mathbf{y}}^f) \quad (48)$$

ここで \mathbf{Y}^f は観測空間における予報摂動行列で，その第 k 列は

$$\mathbf{y}_k^f - \overline{\mathbf{y}}^f, \mathbf{y}_k^f = H(\mathbf{x}_k^f) \quad (49)$$

である。解析誤差共分散は

$$\mathbf{P}^a = [(\mathbf{K} - 1)\mathbf{I} + \mathbf{Y}^{fT} \mathbf{R}^{-1} \mathbf{Y}^f]^{-1} \quad (50)$$

となる。



LETKF: アンサンブル更新


アンサンブルの更新は，解析誤差共分散行列を用いて

$$\mathbf{X}^a = \mathbf{X}^f \mathbf{T} \quad (51)$$

$$\mathbf{T} = \sqrt{(K - 1) \mathbf{P}^a} \quad (52)$$

のように行う。

アンサンブル・カルマンフィルタの予報解析サイクル




ALERA/ALERA2

AFES–LETKF experimental ensemble reanalysis

- 地球シミュレータ用大気大循環モデルAFESにLETKFを適用し，数値天気予報に用いられる全球大気観測データ（放射輝度を除く）を同化。
- ALERA (2005/5 ~ 2007/1): Miyoshi et al. 2007
- ALERA2 (2008/1 ~ 2010/8, 2010/8 ~ 2013/1): Enomoto et al. 2013
- 地球シミュレータセンターから入手可能（ALERA2は準備中）。

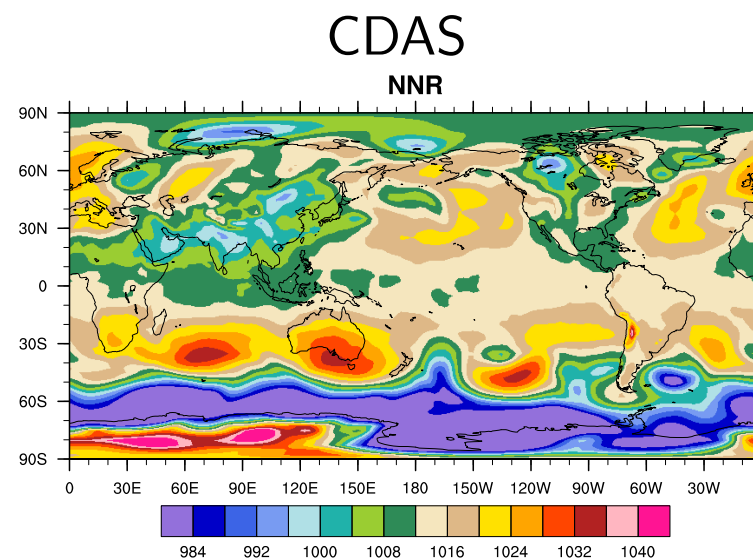
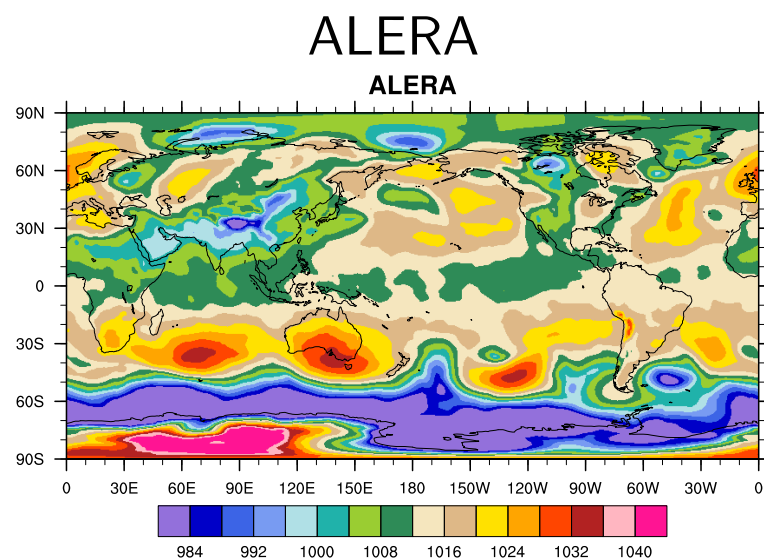


ALEDAS/ALEDAS2のデータフロー



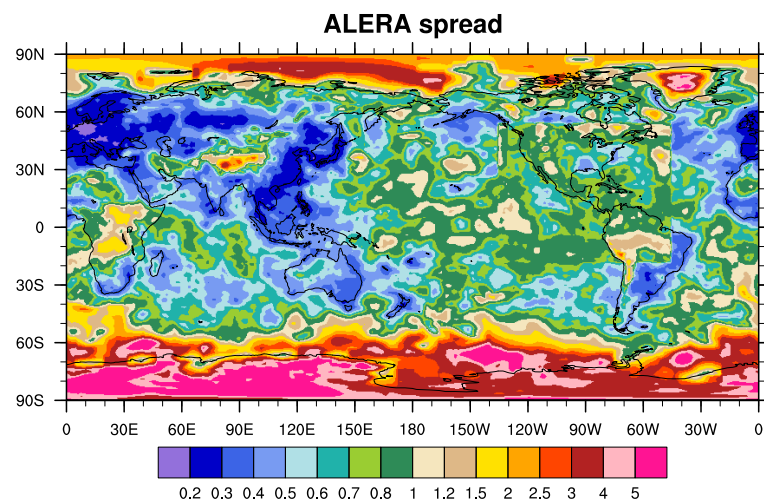
Enomoto et al. 2013

海面気圧のスナップショット

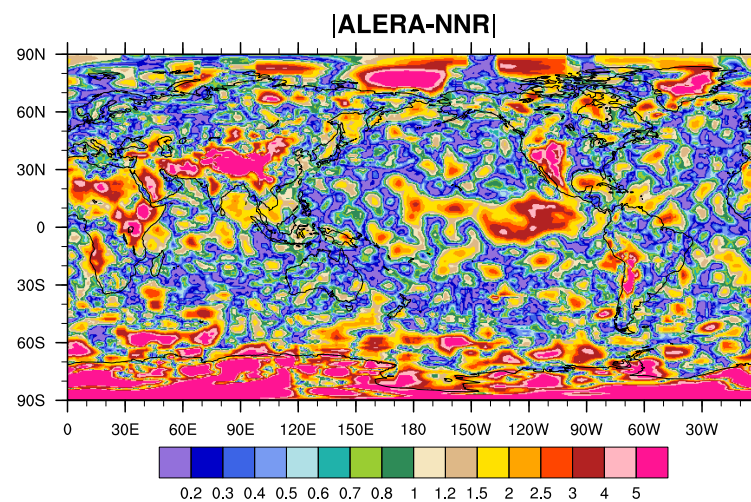


Miyoshi et al. 2007

ALERA スプレッド



ALERA-CDAS

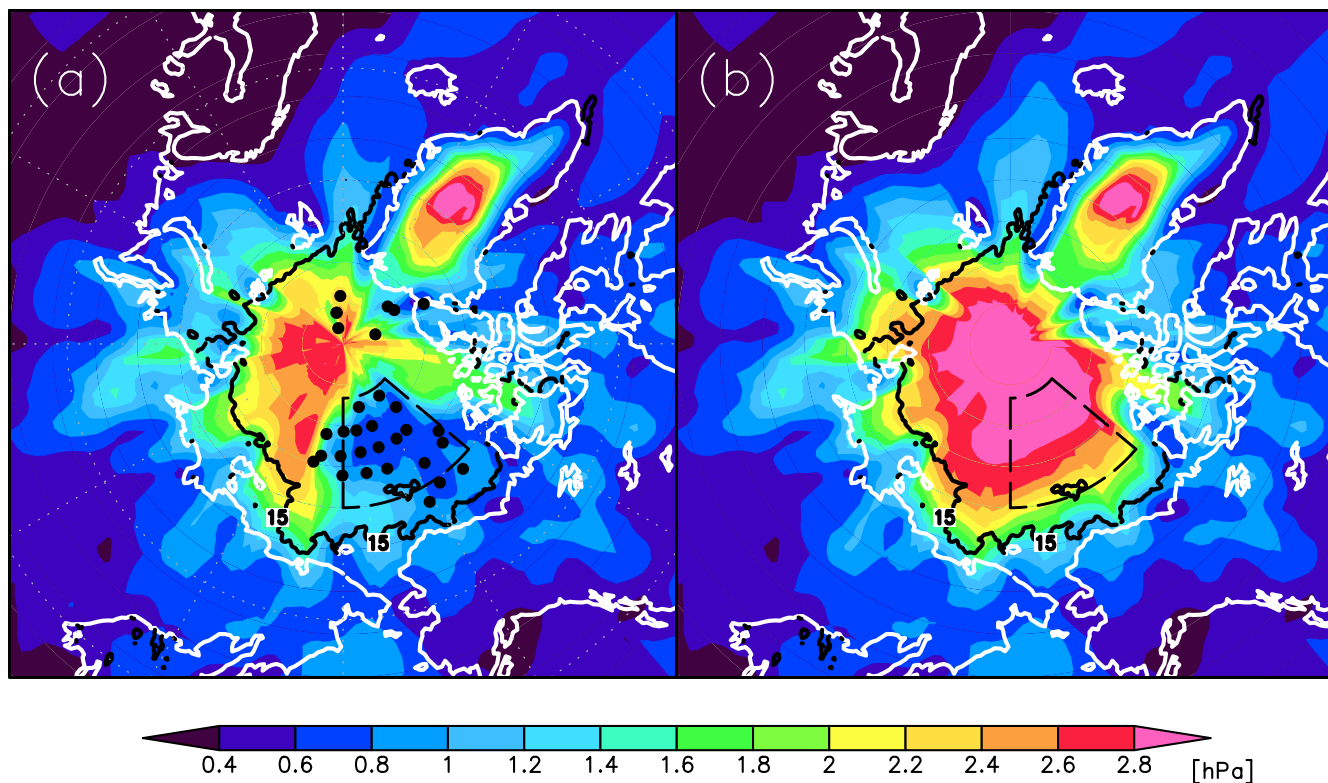


Miyoshi et al. 2007

観測システム実験: 氷上ブイによる気圧観測

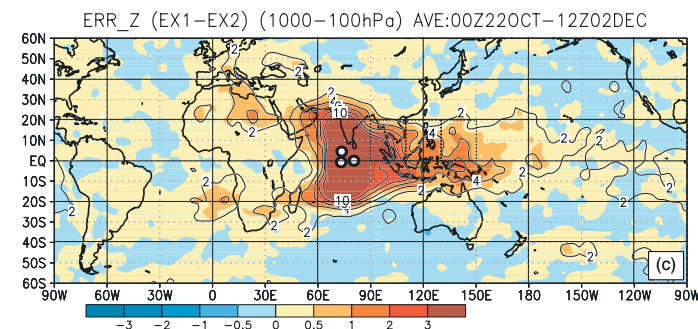
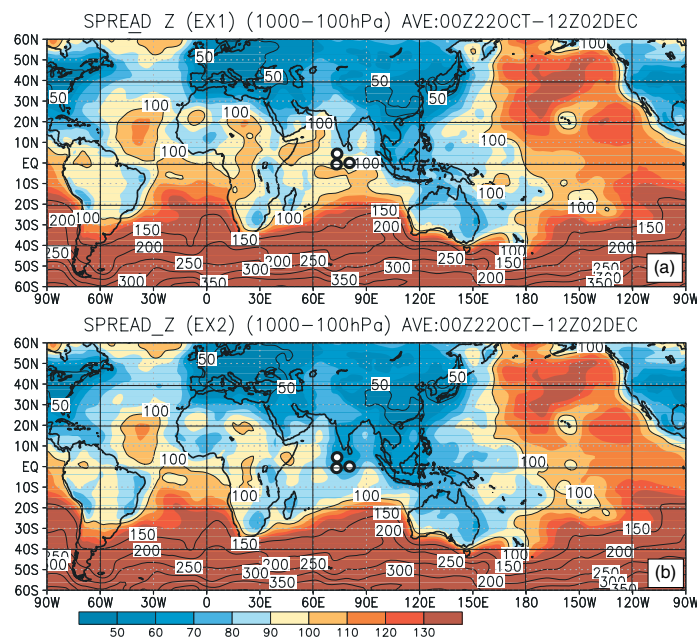
SLP spread in CTL (AUG2006)

SLP spread in ARC (AUG2006)



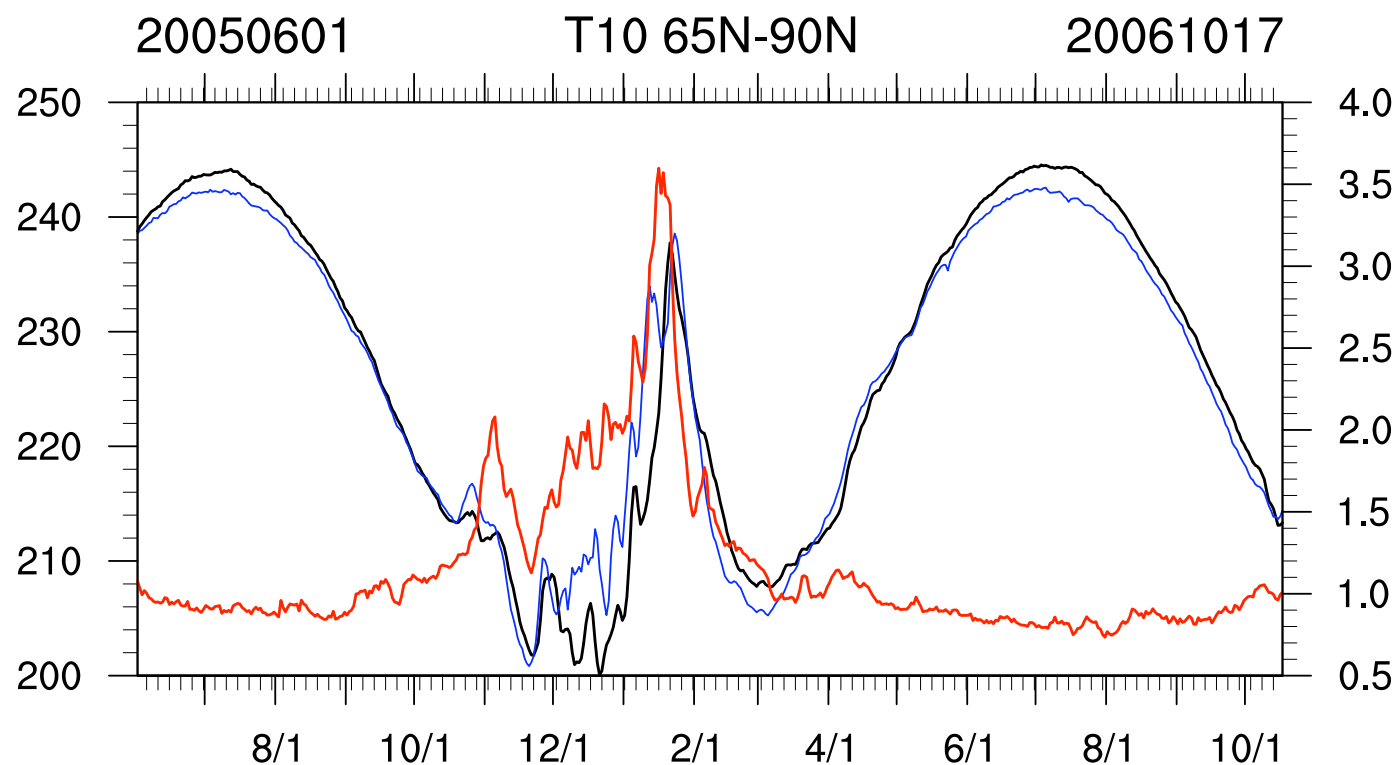
Inoue et al. 2009

観測システム実験: インド洋でのゾンデ観測



Moteki et al. 2011

解析アンサンブルスプレッドが示す予兆 ALERA



Enomoto et al. 2010

ランダム誤差を考慮した弱拘束随伴法

ランダム誤差を考慮する場合は，次の予報方程式を用いる。

$$\boldsymbol{x}_t = \boldsymbol{M}_{t-1}(\boldsymbol{x}_{t-1}) + \boldsymbol{\eta}_{t-1} \quad (53)$$

評価関数は次のようになり，初期値 \boldsymbol{x}_0 及びランダム誤差 $\boldsymbol{\eta}_t$ を推定する。

$$\begin{aligned} J = & \frac{1}{2}(\boldsymbol{x}_0 - \boldsymbol{x}_0^b)^T \mathbf{B}^{-1}(\boldsymbol{x}_0 - \boldsymbol{x}_0^b) \\ & + \frac{1}{2} \sum_{t=0}^T (\boldsymbol{H}_t \boldsymbol{x}_t - \boldsymbol{y}_t)^T \mathbf{R}_t^{-1}(\boldsymbol{H}_t \boldsymbol{x}_t - \boldsymbol{y}_t) \\ & + \frac{1}{2} \sum_{t=0}^{T-1} \boldsymbol{\eta}_t^T \mathbf{Q}_t^{-1} \boldsymbol{\eta}_t \end{aligned} \quad (54)$$

ラグランジュ関数

$$L = J + \sum_{t=1}^T [M_{t-1}(\mathbf{x}_{t-1}) + \boldsymbol{\eta}_{t-1} - \mathbf{x}_t]^T \boldsymbol{\lambda}_t \quad (55)$$

評価関数の勾配は

$$\nabla_{\mathbf{x}_0} J = \frac{\partial J}{\partial \mathbf{x}_0} + \sum_{t=1}^T \mathbf{M}_0^T \mathbf{M}_1^T \cdots \mathbf{M}_{t-1}^T \frac{\partial J}{\partial \mathbf{x}_t} \quad (56)$$

と表されることから, $\boldsymbol{\lambda}_t$ は以下を満たす。

$$\boldsymbol{\lambda}_{t+1} = 0 \quad (57)$$

$$\boldsymbol{\lambda}_t = \mathbf{M}_t^T \boldsymbol{\lambda}_{t+1} + \frac{\partial J}{\partial \mathbf{x}_t} \quad (t = T, T-1, \dots, 0) \quad (58)$$

ここで

$$\frac{\partial J}{\partial \mathbf{x}_0} = \mathbf{H}_0^T \mathbf{R}_0^{-1} [H_0(\mathbf{x}_0) - \mathbf{y}_0] + \mathbf{B}^{-1}(\mathbf{x}_0 - \mathbf{x}_0^b) \quad (59)$$

$$\frac{\partial J}{\partial \mathbf{x}_t} = \mathbf{H}_t^T \mathbf{R}_t^{-1} [H_t(\mathbf{x}_t) - \mathbf{y}_t] \quad (60)$$

このとき $\delta L = \delta J$ となり次を得る。

$$\nabla_{\mathbf{x}_0} J = \boldsymbol{\lambda}_0 \quad (61)$$

$$\nabla_{\boldsymbol{\eta}_t} J = \mathbf{Q}_t^{-1} \boldsymbol{\eta}_t + \boldsymbol{\lambda}_{i+1} \quad (t = 0, 1, \dots, T - 1) \quad (62)$$

例: 酔歩

評価関数

$$J = \frac{(x_0 - x_b)^2}{2\sigma_b^2} + \sum_{t=0}^T \frac{(x_t - y_t)^2}{2\sigma_{rt}^2} + \sum_{t=0}^{T-1} \frac{\eta_t^2}{2\sigma_\eta^2} \quad (63)$$

勾配


$$\nabla_{x_0} J = \frac{x_0 - x_b}{\sigma_b^2} + \sum_{t=0}^T \frac{x_t - y_t}{\sigma_{rt}^2} \quad (64)$$

$$\nabla_{\eta_t} J = \frac{\eta_t}{\sigma_\eta^2} + \sum_{t=t+1}^T \frac{x_t - y_t}{\sigma_{rt}^2} \quad (65)$$

酔歩: 随伴法

- 初期値 x_0 とモデルのランダム誤差 q を推定。
- x ($t \neq 0$) はモデルで予測。
- コスト関数, 勾配を計算。
- 線型探索をして降下法, 共役勾配法の刻み幅を決定。
- ソースは長いので省略。
- 収束が遅い。ランダムだから?





まとめ

- カルマンフィルタ: 解析時刻まで得られた連続的な観測を逐次的に同化。重みは最適内挿法と同形, 誤差の少ないデータに大きな重み。
- カルマンスムーザ: 解析時刻より先のデータも利用できる場合, カルマンフィルタを後方にも適用, 前方の予報と組み合わせ誤差をより減少。
- 拡張カルマンフィルタ: モデルと観測演算子を線型化することで非線型問題にも適用可。
- アンサンブル・カルマンフィルタ: アンサンブル予報を使って予報誤差共分散を近似。